可重复性数据分析及其工业实践

第 13 届中国 R 语言会议

黄湘云

2021年01月03日

1



Literate programming is a programming paradigm introduced by Donald Knuth in which a computer program is given an explanation of its logic in a natural language, such as English, interspersed with snippets of macros and traditional source code, from which compilable source code can be generated.

¹https://en.wikipedia.org/wiki/Literate_programming

下面以 utils 包提供的测试文档为例

注意

若已安装 LaTeX 发行版 $TinyTeX^2$,需要再装三个 LaTeX 宏包 a4wide、ntgclass 和 ae,以供文档编译

```
tinytex::tlmgr_install(c('a4wide', 'ntgclass','ae'))
```

²https://github.com/yihui/tinytex

Sweave II

नर जर जर जर जर जर



图 1: 形式上是 LaTeX 和 R 代码的混合物

,

A minimal R Markdown document ³

المراواع والمراواع والمراواة والمراواة


```
title: "A Simple Regression" #----
author: "Yihui Xie"
date: "2019-01-02"
                                # |--> metadata
output:
  html document:
    toc: true
                                #----
We built a linear regression model. <!-- narrative -->
```{r}
fit <- lm(dist ~ speed, data = cars)
b <- coef(fit)</pre>
plot(fit)
The slope of the regression is `r b[1]`. <!-- narrative w/ code --
3https://slides.yihui.org/2020-covid-rmarkdown.html#7
```

### Knit R Markdown to Markdown

والموال والموال والموال والموالي والموالي والموالي والموالية


```
_ _ _
title: "A Simple Regression" #----
author: "Yihui Xie"
date: "2019-01-02"
 # |--> metadata
output:
 html_document:
 #----
 toc: true
We built a linear regression model. <!-- narrative -->
fit <- lm(dist ~ speed, data = cars)
b <- coef(fit)
plot(fit)
![a plot](input_files/figure-html/unnamed-chunk-1.png)
The slope of the regression is -17.58. <!-- narrative w/ code -5>
```

#### R Markdown 思维导图4



<sup>&</sup>lt;sup>4</sup>https://github.com/rstudio/concept-maps#r-markdown

## 编译 R Markdown 文档的过程5



R Markdown = knitr (Literate Programming)

+ Pandoc

(+ LaTeX for PDF output)

<sup>&</sup>lt;sup>5</sup>https://slides.yihui.org/2020-covid-rmarkdown.html#7

#### 从 Sweave 到 R Markdown

والموال والمراوال والموال والموال والموال والموال والموال والموالية



9

#### R Markdown 生态环境




#### R Markdown 过去 vs 现在


最大的不同在于稳健性和生态圈,基本覆盖 Word / LaTeX 支持的文档处理功能,满足大部分数据分析的场景,比如毕业论文、期刊论文、课程作业、幻灯片、分析报告等。 高级的特性依然需要相当的技术实力支撑,包括 Pandoc、Lua、LaTeX、CSS、HTML、 JavaScript、Git 和 R,在数据分析师这个行业,它们形成了一簇相当陡峭的学习曲线。 然鹅,有时候真正干活的是搜索引擎和 Ctrl + C/V!

#### 数据分析工作流

الماع والمراوا والمرا



المراوا والمراوا والم



面对大量的数据时,探索性分析是一件极其困难的事情!

```
连接 Spark
library(sparklyr)
sc <- spark_connect(</pre>
 master = "local[2]",
 spark home = Sys.getenv("SPARK HOME")
准备数据
tbl <- copy to(sc, ggplot2::diamonds, "diamonds")
数据查询
library(DBI)
diamonds_db <- dbGetQuery(sc, "</pre>
 SELECT count(*) as cnt, cut FROM diamonds GROUP BY cut
```

```
关闭连接
spark disconnect(sc)
数据探索
library(ggplot2)
ggplot(diamonds db, aes(cut, cnt)) +
 geom col() +
 theme_minimal()
数据呈现
library(plotly)
diamonds db %>%
 plot ly(x = ~cut, y = ~cnt, type = "bar") %>%
 add text(
 text = ~ scales::comma(cnt), y = ~cnt,
 textposition = "top middle",
```

# 探索性分析 (续)

```
cliponaxis = FALSE, showlegend = FALSE
) %>%
config(displayModeBar = FALSE)
```

然鹅。。。

#### 请从配置环境开始

```
安装 openidk 11
brew install openidk@11
全局设置 JDK 11
sudo ln -sfn /usr/local/opt/openjdk@11/libexec/openjdk.jdk \
 /Library/Java/JavaVirtualMachines/openjdk-11.jdk
Java 11 JDK 添加到 .zshrc
export CPPFLAGS="-I/usr/local/opt/openjdk@11/include"
export PATH="/usr/local/opt/openjdk@11/bin:$PATH"
配置 R 环境
sudo R CMD javareconf
安装 rJava 包
Rscript -e 'install.packages(c("rJava", "sparklyr"))'
```

#### 然鹅, 请从下载软件开始

手动从官网下载 Spark 软件,配置变量。。。

والماران والمراوا والموام والمراوا والمراوا والموام والموام المراوا والموام المراوا والموام المراوات

#### 然鹅, 请从下载软件开始

手动从官网下载 Spark 软件, 配置变量。。。



Spark 依赖特定版本的 Java、Hadoop, 三者之间的版本应该要相融。

#### 然鹅, 请从下载软件开始

手动从官网下载 Spark 软件, 配置变量。。。



Spark 依赖特定版本的 Java、Hadoop, 三者之间的版本应该要相融。

回到开头, 重新下载软件, 配置环境, 再来三遍。

一周过去了,终于可以开始干点活了。。。

#### 数据可视化




图 2: 柱形图

#### 数据可视化 (续)




图 3: 条形图

#### 然鹅,要这样。。。





图 4: 交互条形图

工业实践



szigelszigelszigelszigelszigelszigelszigelszigelszigelszigelszigelszigelszigelszigelszigelszigelszigelszigelsz

<sup>&</sup>lt;sup>6</sup>https://github.com/openanalytics

### 分层结构

数据中心 数据仓库 调度系统 代码管理 开发 测试 部署 代理 用户 用户 用户

spistojelspistojelspistojelspistojelspistojelspistojelspistojelspistojelspistojelspistojelspistojelspistojelsp



